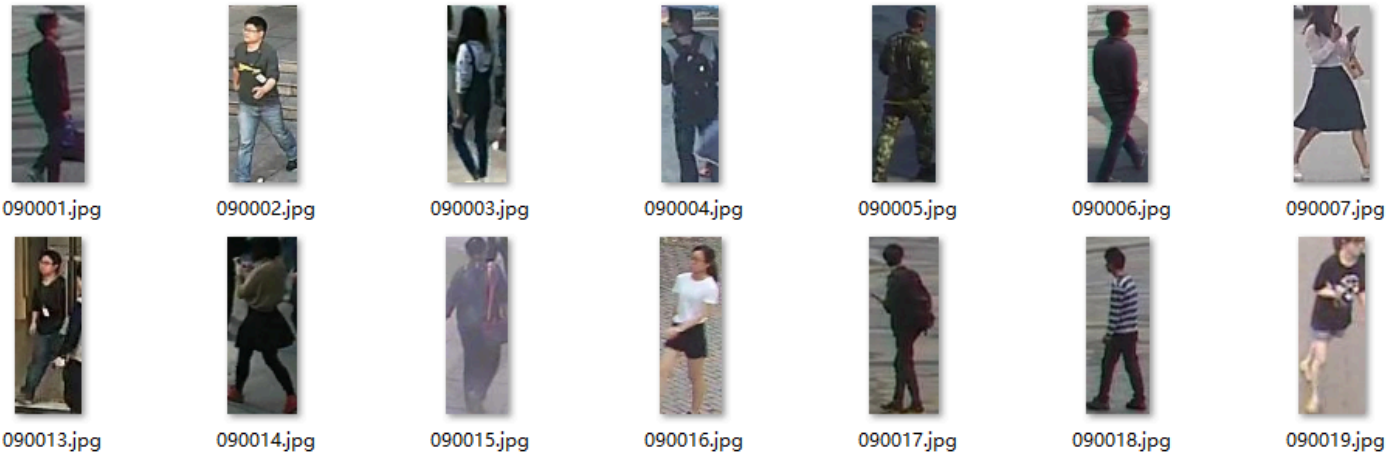
挑战项目二

多标签非均衡样本的行人属性分类

一、项目背景

行人属性识别（Pedestrian Attribute Recognition, PAR）是智能监控、行人检索等应用中的基础任务：给定一张行人裁剪图，同时判断其性别、年龄段、朝向、衣着款式、携带物等多个属性。它不关心"这个人是谁"，而是回答"这个人长什么样、穿什么、带了什么"这类结构化问题。

本项目基于经典公开数据集 **PA100K 数据集**（80,000 张训练行人裁剪图，每张标注 26 个属性，分属 9 个属性组），训练一个行人属性识别模型。属性组之间存在三种不同的分类语义：**binary**（单个二值属性）、**softmax**（组内互斥）、**multilabel**（组内可共存），它们对应不同的损失函数设计——这本身就是多标签学习中最值得体会的一点。



与"从零搭建"不同，本项目提供一个**可直接运行的 baseline**（ResNet18 + 分组分类头 + 三种损失的朴素实现）。你的任务不是从零搭建，而是**读懂 baseline、跑通 baseline、然后改进它**：亲自修改网络结构或损失函数，用相同的训练配置重新训练，与 baseline 做公平的对比项目，形成"提出假设 → 项目验证 → 分析结论"的科研闭环。结果无论好坏都要记录——指标下降也是正常的项目结论，只要分析到位。

此外，PA100K 存在严重的类别不平衡（如 `boots` 正例不足 1%），如何用指标（mA）与加权策略（pos_weight、Focal Loss）应对这类问题，也是本项目的重要一课。

二、项目目的

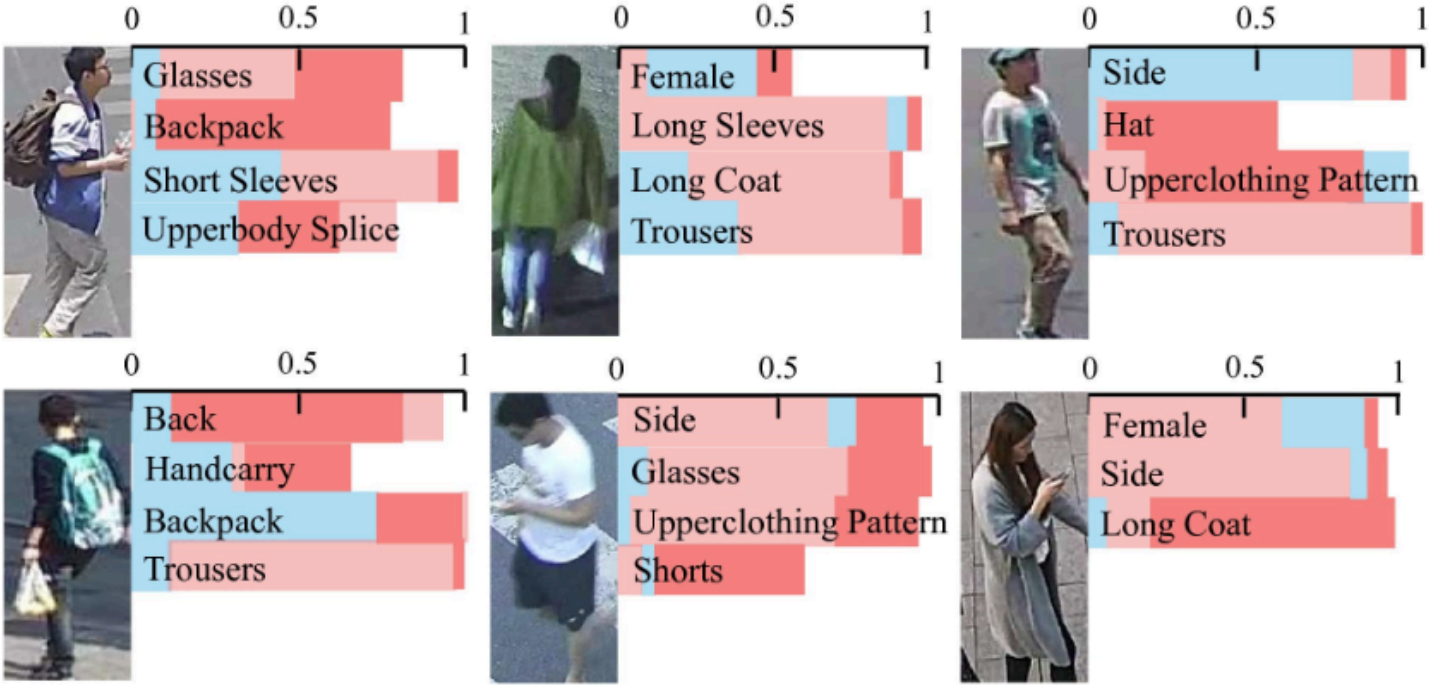
完成本项目后，应能够：

1. **掌握图像分类完整流程**：数据加载与增强 → 模型构建 → 训练 → 评估 → 推理；
2. **理解多标签分类**：区分多标签分类与互斥多分类，掌握 `BCEWithLogitsLoss` 与 `CrossEntropyLoss` 的适用场景与设计差异；
3. **理解迁移学习**：解释为什么小数据集上要使用 ImageNet 预训练权重；
4. **理解类别不平衡**：识别不平衡属性，学会用 mA、pos_weight、Focal Loss 等指标与策略应对；
5. **掌握对比项目方法**：在可运行 baseline 之上修改结构或损失函数，通过控制变量的对比项目验证想法。

三、项目概要

端到端流程：PA100K 行人裁剪图 → `Resize` 到 256×128 → `ToTensor` 与 ImageNet 归一化 → 随机增强（例如：水平翻转、ColorJitter、RandomErasing）→ ResNet18 backbone（ImageNet 预训练、去掉 fc）提取 512 维特征 → 9 个分组分类头 → 按组计算 `BCEWithLogitsLoss` / `CrossEntropyLoss` 并加权求和 → 反向传播训练 → AttrAcc、mA、实例级 Precision/Recall/F1 评估 → `infer.py` 推理演示与结果可视化。

核心思想：共享 backbone 让所有属性共享底层视觉特征（边缘、颜色），分组分类头让每组使用适合自己语义的损失函数；用迁移学习弥补小数据，用加权策略对抗类别不平衡；最重要的是把"提出假设 → 公平对比 → 分析结论"贯穿整个项目，每一次修改都要能归因。



四、项目步骤

步骤一：环境与数据探索

- 安装依赖（Python 3.10+、PyTorch ≥ 2.0，GPU 4GB 显存即可，无独显可调小 batch 或 epoch）；
- 运行 `python dataset.py`，观察样本数与各属性正例率，思考哪些属性最不平衡；
- 随机读取 9 张训练图并输出它们的属性标签，检查数据加载是否正确。

步骤二：跑通 baseline

- 通读 `starter_code/` 全部代码：`dataset.py` 如何组织标签、`model.py` 如何分组输出、`losses.py` 如何按组计算损失、`evaluate.py` 如何按组统计准确率；
- 启动训练（`python train.py --epochs 15 --batch-size 64`），训练结束后用 `infer.py` 测试几张图；
- 记录 baseline 的各组准确率与逐属性准确率——**这份数字是后续所有改进的对照组，务必保存好**。

步骤三：提出改进并验证

- 修改方向(**至少选择一项**)：损失函数（pos_weight 加权 / Focal Loss / Margin Softmax）、网络结构（更深 backbone / SE 注意力 / 共享底层分组顶层）、数据与训练策略（增强 / 标签平滑 / 分组采样）等；
- 修改必须有明确动机（为什么这样改？预期解决什么问题？），对比必须公平（只改一个因素，其余超参数保持一致）；
- 结果无论好坏都要记录，指标下降也是正常的项目结论，分析原因即可。

步骤四：失败分析与报告

- 在验证集上找出 5 张以上预测错误的图片，逐张分析错误原因（遮挡、模糊、属性本身难区分、标注噪声）；
- 找出最容易混淆的属性对，分析原因并提出进一步改进设想；

五、提交内容

1. Python 源代码（requirements.txt、README 运行说明、完整的代码）；
2. 模型文件：训练得到的 `best.pt`；
3. 演示结果：`infer.py` 对至少 3 张测试图的输出截图。
4. 项目报告

5. **不提交PA100K数据集**

参考资料

1. Li, D., Chen, X., Zhang, Z., & Huang, K. Multi-Attribute Learning for Pedestrian Attribute Recognition in Surveillance Scenarios, ICPR 2018（PA100K 数据集）
2. He, K., Zhang, X., Ren, S., & Sun, J. Deep Residual Learning for Image Recognition, CVPR 2016
3. Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. Focal Loss for Dense Object Detection, ICCV 2017